TRABAJO: EVALUACIÓN DE LA SEGMENTACIÓN

Informe para la Actividad 2 de la asignatura Percepción Computacional

Presentado por: Omar Javier Daza Leguizamón

Fundación Universitaria Internacional de La Rioja
Especialización en Inteligencia Artificial
Octubre de 2026

Contenido

Introducción 3
1. Descripción de los datos empleados 3
2. Métricas de evaluación 5
3. Segmentadores 6
4. Evaluación comparativa de segmentadores 8
5. Análisis de los resultados 9
6.Conclusiones 10
Bibliografía 11

Introducción

En el contexto de la gestión de la infraestructura vial, la auscultación de pavimentos es un insumo para la programación de intervenciones preventivas. En Colombia, uno de los referentes del tema es la norma ASTM D6433, que cuantifica el estado del pavimento mediante el índice de condición (PCI). Con este índice se estima la severidad y la extensión de los deterioros superficiales del pavimento; entre estos, las fisuras son de las más frecuentes y de los primeros defectos en manifestarse visualmente (ASTM International, 2024; Shahin, 2005). La subjetividad y el costo de la inspección visual tradicional han impulsado el uso de imágenes como alternativa a la auscultación (Koch et al., 2015; Zakeri et al., 2017). Sin embargo, en Colombia, en las entidades encargadas de la gestión de pavimentos no es común utilizar metodologías distintas de las tradicionales y, por todo lo anterior, en esta actividad académica se indagan metodologías transferibles y aplicables, apoyadas en el uso de software de código abierto.

En la Actividad 1 se abordó la primera etapa del procesamiento de imágenes del pavimento: la eliminación del ruido impulsivo mediante un método que detecta y corrige únicamente los píxeles anómalos para preservar las fisuras. La etapa siguiente es la segmentación, es decir, separar los píxeles que pertenecen a la fisura del resto de la superficie (Gonzalez y Woods, 2018; UNIR, s. f., tema 10). La máscara binaria resultante es la base para medir la longitud, el ancho y el área afectada que exigen los índices de condición.

Segmentar fisuras es una tarea difícil debido a las características propias de estas imágenes. Las fisuras son estructuras muy finas; por ejemplo, en el conjunto de datos *CrackForest* (utilizado en la actividad 1) miden en promedio unos 3 píxeles de ancho y ocupan alrededor del 1 % de la imagen, por lo que las clases están fuertemente desbalanceadas. Sumado a lo anterior, el contraste de la fisura con el fondo es bajo, la textura del agregado produce manchas oscuras similares a una fisura y la iluminación no es uniforme. Estas condiciones también afectan el proceso de evaluación porque en una estructura de 3 píxeles, un desplazamiento de un solo píxel entre la segmentación y la anotación manual reduce drásticamente las métricas de solapamiento, aunque la fisura esté bien localizada.

El objetivo de este ejercicio es construir y comparar tres segmentadores de fisuras basados en técnicas clásicas con fundamentos distintos. Para este caso, se recurre a la umbralización global de Otsu, al crecimiento de regiones a partir de semillas y a la transformada *Watershed* con marcadores. El rendimiento se evalúa frente a imágenes de *Ground Truth* anotadas manualmente, mediante un módulo de evaluación de implementación propio que combina métricas de solapamiento estricto con métricas con tolerancia espacial, adecuadas para estructuras finas. Se emplean dos conjuntos de datos públicos: *CrackForest* (Shi et al., 2016), ya utilizado en la Actividad 1, y *DeepCrack* (Liu et al., 2019).

1. Descripción de los datos empleados

Dando continuidad a la actividad 1, en este ejercicio se utilizan dos conjuntos públicos de imágenes de pavimento con máscaras de fisura anotadas manualmente a nivel de píxel; uno de ellos es el mismo que en la actividad anterior. La elección de estos datos se justifica porque sus fisuras presentan grosores distintos, lo que permite analizar cómo influye el ancho de la estructura tanto en los segmentadores como en las métricas de evaluación. En la siguiente tabla se presentan las características de los datos utilizados y su carga y verificación se implementan en el notebook (Notebook, celda [2]). Ambos conjuntos se distribuyen con autorización de uso para fines de investigación y educativos no comerciales, y se emplean aquí en ese marco académico. Las imágenes se leen en escala de grises de 8 bits (con valores de 0 a 255). El código se entrega en el notebook Actividad2_Pavimentos.ipynb, anexo a este informe; las referencias del tipo (Notebook, celda [n]) remiten al número de ejecución de sus celdas.

Tabla 1. Descripción de los conjuntos de datos utilizados.

	***CrackForest* (CFD)**	***DeepCrack***
Referencia	Shi et al. (2016)	Liu et al. (2019)
Imágenes con *ground truth*	118 (de 155 imágenes)	537 (300 de *train* y 237 de *test*)
Tamaño	480 × 320 píxeles	544 × 384 píxeles (horizontal o vertical)
Superficie	Pavimento asfáltico urbano	Pavimento y otras superficies variadas
Fisuras	Finas, de bajo contraste	Más anchas y de mayor contraste
Imágenes utilizadas en este trabajo	115 (118 menos 3 excluidas por control de calidad)	257 (20 de *train* para calibración y las 237 de *test*)

Como parte del control de calidad, antes de aplicar cualquier algoritmo, se verifica que cada anotación corresponda realmente a su imagen mediante dos criterios aplicados a las 655 imágenes con *Ground Truth* (Notebook, celda [3]). Esta verificación consiste, primero, en identificar *Ground Truth* duplicados en el conjunto de datos que están asignados a imágenes distintas y, segundo, en identificar Ground Truth desalineados con respecto a la imagen original. Para este segundo caso, se desplaza el eje de la anotación hasta ±30 píxeles y se mide el realce de fisura bajo él; la anotación se considera desalineada si el mejor ajuste está a más de 2 píxeles, la tolerancia de las métricas, y mejora el ajuste original en al menos un 25 %. Las imágenes que cumplen con alguno de los dos criterios se excluyen de los análisis posteriores; en este caso, las imágenes 023, 042 y 054 del conjunto de datos de CrackForest se excluyen finalmente.

Los datos se dividen en dos subconjuntos que no comparten imágenes entre sí; esto se hace para utilizar uno de ellos para la calibración y el otro para la evaluación. Los datos del conjunto de calibración se utilizan para seleccionar los parámetros de cada segmentador, y los del conjunto de evaluación se emplean para medir el rendimiento final (ver última fila de la tabla 1). Las 280 imágenes restantes del subconjunto *train* de DeepCrack no se utilizan: ese subconjunto está pensado para entrenar redes neuronales, mientras que los segmentadores de este trabajo solo tienen unos pocos parámetros, para los cuales son suficientes 20 imágenes. El proceso de partición es aleatorio con una semilla fija, haciéndolo reproducible. Se verificó que ninguna imagen de evaluación repite el contenido de una calibración (Notebook, celda [4]). La figura 1 muestra las imágenes de calibración con menor y mayor proporción de fisura para los dos grupos de datos (Notebook, celda [5]).

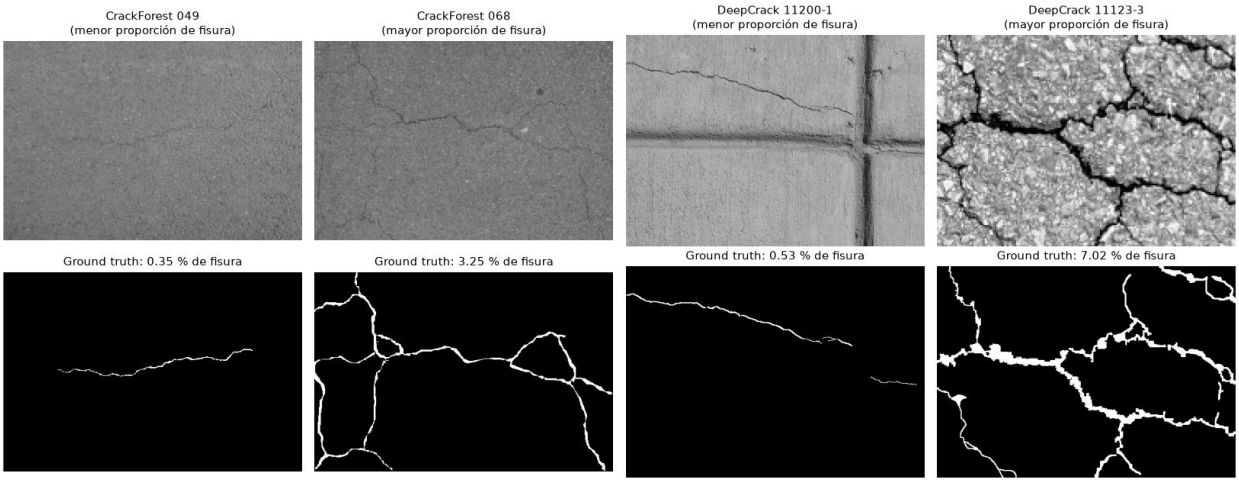


Figura 1. Imágenes de calibración con menor y mayor proporción de fisura de cada conjunto y su Ground Truth."

Complementariamente, se estiman la proporción de fisura y el ancho medio de las fisuras (Notebook, celda [6]). Esto se hizo porque estas propiedades condicionan el diseño de los segmentadores y la elección de las métricas. La proporción de fisura es el porcentaje de pixeles de la imagen que pertenecen a la fisura,

mostrando el grado de desbalance entre las dos clases (con fisura y sin fisura). El ancho medio de las fisuras se estima con el eje medial (técnica morfológica matemática tratada en el Tema 8). La caracterización se calcula sobre las 372 imágenes (calibración y evaluación) de los dos conjuntos de datos y el resultado se puede ver en la figura 2.

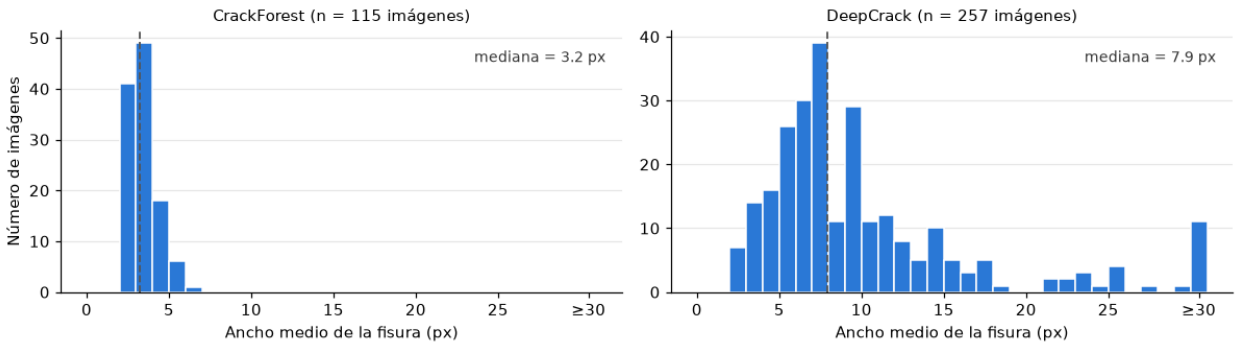


Figura 2. Distribución del ancho medio de fisura por imagen (CrackForest, n = 115; DeepCrack, n = 257

La caracterización presentada permite mostrar que los dos conjuntos plantean problemas distintos y anticipa cuatro decisiones de diseño. La primera es que se necesitan métricas centradas en la clase fisura, porque un segmentador que no detectara ninguna fisura obtendría una exactitud cercana al 99% en el conjunto de datos de *CracForest*. La segunda es complementar las métricas de solapamiento con métricas de tolerancia espacial, esto considerando que en una estructura de grosor entre 2 y 6 pixeles un error de un pixel en el borde equivale a un tercio del ancho. La tercera lleva a que los resultados se reporten por separado para cada conjunto de datos: el ancho mediano de DeepCrack (7,90 pixeles) es más del doble que el de CrackForest, con un rango mucho más amplio (2,35 a 50,14 pixeles). Finalmente, en consecuencia con lo expuesto, la cuarta es que los parámetros de los segmentadores se ajustarán por separado en cada conjunto.

2. Métricas de evaluación

Para la evaluación de los segmentadores, se utiliza una matriz de confusión implementada en el Notebook (Notebook, celda [7]). En el material de referencia de la asignatura no se definen métricas de evaluación, por lo que se adoptan las propuestas del documento complementario de la actividad aportado por el docente (Notebook, celda [8]):

- *IoU* (índice de Jaccard; Jaccard, 1912): fracción de la unión de la máscara producida por el segmentador y la máscara de *ground truth* que corresponde a su intersección. Vale 1 si las máscaras coinciden exactamente y 0 si no se solapan.
- *Dice* (Dice, 1945): mide lo mismo que *IoU*, pero da el doble de peso a la intersección. Coincide con el *F1* a nivel de píxel y está ligado al *IoU* por la relación $Dice = 2 * IoU/(1 + IoU)$, propiedad que se utiliza para validar el evaluador (Notebook, celda [10]).
- Precisión: de todo lo que el segmentador marcó como fisura, qué fracción lo era realmente. Penaliza las falsas alarmas.
- Sensibilidad (*Recall*): de toda la fisura real, qué fracción se detectó. Penaliza las fisuras perdidas.
- Exactitud: La exactitud, $(TP + TN)/N$, donde *N* es el número total de píxeles, se calcula solo para mostrar por qué no es adecuada. Como el fondo representa en torno al 99 % de los píxeles, la exactitud es casi perfecta incluso para un segmentador inútil. Un segmentador que no detecta nada obtiene una exactitud de 0,986 en *CrackForest* y de 0,967 en *DeepCrack*, con IoU = 0 (Notebook, celda [8])."

Algunas fórmulas de las métricas anteriores pueden provocar una división por cero. Para que el resultado esté siempre definido, se adopta una convención explícita (Maier-Hein et al., 2024; Taha y Hanbury, 2015). Si tanto la matriz producida por el segmentador como la máscara de ground truth están vacías, el acuerdo es perfecto y la métrica es 1. En cualquier otro caso en que el denominador sea cero, la métrica es 0. Por ejemplo, la precisión de un segmentador que no detecta nada en una imagen que sí tiene una fisura.

Considerando lo encontrado en la caracterización previamente descrita, para estructuras tan finas, si la segmentación sigue correctamente la fisura pero queda desplazada 1 píxel respecto a la anotación manual, el IoU y el Dice caen bruscamente. Por lo tanto, se incluyen dos métricas que buscan suplir este problema:

- *F1* con tolerancia espacial ($F1_\tau$): Sigue el criterio de correspondencia con tolerancia del *benchmark* de contornos de Berkeley (Martin et al., 2004): un píxel detectado se considera correcto si existe un píxel de fisura del *ground truth* a una distancia no mayor que τ, y viceversa. Mide si la fisura está bien localizada. Se adopta $\tau = 2$ píxeles. Su formulación está en el notebook (Notebook, §2.3, celda [9]).
- *clDice* (Shit et al., 2021): Es una métrica diseñada para estructuras tubulares delgadas, como vasos sanguíneos, carreteras o fisuras. En lugar de comparar las áreas, compara las líneas centrales (esqueletos) de ambas máscaras y mide si se conserva la continuidad de la fisura, lo que determina su longitud en la auscultación. Su formulación está en el notebook (Notebook, §2.3, celda [9]).

El evaluador se validó con 12 casos de resultado conocido antes de aplicarlo a los segmentadores (Notebook, celda [10]) mediante máscaras idénticas, disjuntas y vacías; un ejemplo de 2 × 4 píxeles calculado a mano; la relación entre *Dice* e *IoU* en 200 pares aleatorios; la simetría de las métricas, y dos casos de líneas finas. Por otro lado, para cuantificar el efecto de los errores de borde, se perturbó el *Ground Truth* de las 40 imágenes de calibración y se evaluó como si fuera una segmentación (Notebook, celda [11]). En *CrackForest*, desplazarlo 2 píxeles reduce el *IoU* medio a 0,31 y el *clDice* a 0,37, mientras que $F1_\tau$ se mantiene en 1,00; en *DeepCrack*, el mismo desplazamiento deja el *IoU* en 0,61. Engrosarlo 1 píxel apenas cambia el *clDice* (0,99), y la exactitud supera 0,98 en todos los casos. Cada métrica responde, por tanto, a un tipo de error: *IoU* y *Dice* al solapamiento exacto, $F1_\tau$ a la localización y *clDice* a la continuidad del eje; además, el valor de IoU y Dice depende del grosor de la fisura. Los aciertos y errores se visualizan con un mapa de colores (verdaderos positivos, falsos positivos y falsos negativos) que se usa en todas las figuras de resultados (Notebook, celda [12]).

3. Segmentadores

Para dar cumplimiento al objetivo de la actividad, se comparan tres segmentadores con fundamentos diferentes (ver la tabla 2), aplicados a las mismas imágenes preprocesadas, de modo que las diferencias de rendimiento sean consecuencia de la estrategia de segmentación y no de la preparación de las imágenes. El preprocesado consistió en suavizado gaussiano y realce *black-hat*, que destaca las estructuras oscuras y finas (Notebook, celda [13]).

Tabla 2. Segementadores utilizados para el desarrollo de la actividad.

Segmentador	Enfoque	Fundamento	Material de la asignatura	Implementación	Celda de Notebook
S1. Umbral de Otsu	Global, basado en el histograma	Un único umbral para toda la imagen (Otsu, 1979)	Histograma (tema 6)	Librería *scikit-image*	[14]
S2. Crecimiento de regiones	Local, *bottom-up*	Semillas y agregación de vecinos según un criterio de pertenencia	Tema 10, sección 10.4	Propia	[15]

S3. *Watershed* con marcadores	Morfológico, topográfico	Inundación de la imagen de gradiente desde marcadores (Beucher y Lantuéjoul, 1979; Vincent y Soille, 1991; Meyer y Beucher, 1990)	Tema 10, sección 10.7	Librería *scikit-image*	[16]

S1 actúa como línea base para representar la segmentación más simple posible y permite medir cuánto aportan los otros dos métodos. Los umbrales para S2 y S3 se expresan como percentiles del realce de cada imagen, no como valores absolutos. Por ejemplo, "las semillas son el 0,5 % de los píxeles con mayor realce". Así, el mismo parámetro se adapta al contraste de cada imagen, que varía según la iluminación y la superficie. Los segmentadores S1 y S3 corresponden a métodos descritos en las referencias de la tabla 2, por lo que no se detallan en este informe; por otro lado, en el segmentador S2 se implementa el crecimiento de regiones basado en semillas del tema 10 (sección 10.4) con sus tres ingredientes:

- Semillas: píxeles iniciales a partir de los cuales crece la región. En el material de la asignatura, las semillas suelen elegirse manualmente o mediante interacción. Para este caso se eligen automáticamente los píxeles con mayor realce *black-hat* (por encima de $p_{semilla}$), es decir, los puntos donde la presencia de fisura es más segura. Esta implementación se justifica por la necesidad de que el método sea reproducible y no dependa de la elección manual de la imagen.
- Función de similaridad: la propiedad que se compara es el realce *black-hat f(p)*, que mide cuánto más oscuro es un píxel que su entorno inmediato. No se usa la intensidad directa porque la textura del asfalto presenta intensidades similares a las de la fisura. Con la intensidad, la región se fuga hacia el fondo.
- Función de pertenencia: un píxel *p* adyacente a la región (vecindad 8) se incorpora si $f(p) \geq u_{crec}$, donde u_{crec} es el percentil $p_{crecimiento}$ del realce de la imagen. La región crece iterativamente hasta que ningún vecino cumple la condición.

El resultado es que la región parte de los tramos más evidentes de la fisura y avanza por píxeles de realce moderado solo si estos están conectados a ella. La textura aislada, aunque presente un realce similar, no se incorpora porque no está unida a ninguna semilla. Es la misma idea que el detector de Canny utiliza para conservar los bordes débiles conectados a bordes fuertes (tema 7 del material de estudio). Finalmente, se eliminan los objetos de área menor que el mínimo.

Los parámetros de cada segmentador se eligen por separado para cada conjunto, buscando en una rejilla de valores el que maximice el *F1* con tolerancia media en las 20 imágenes de calibración de cada conjunto de datos de referencia (198 combinaciones en total). Se usa el *F1* con tolerancia como criterio porque mide la localización de la fisura sin penalizar la imprecisión de la anotación manual. El *Dice* de cada combinación se registra para comprobar que ambos criterios coinciden.

Tabla 3. Calibración de parámetros seleccionados.

Segmentador	Parámetros calibrados	Combinaciones por conjunto	Seleccionados en CrackForest	Seleccionados en DeepCrack
S1 Otsu	radio *black-hat*, área mínima	3 × 3 = 9	r = 3; A = 100	r = 10; A = 100
S2 Crecimiento de regiones	radio, $p_{semilla}$, $p_{crecimiento}$, área mínima	3 × 3 × 3 × 2 = 54	r = 5; 99,5; 90; A = 100	r = 20; 99,5; 94; A = 100
S3 Watershed	radio, p_{fondo}, p_{fisura}, área mínima	3 × 3 × 2 × 2 = 36	r = 5; 95; 98; A = 30	r = 30; 90; 99; A = 100

Los radios candidatos varían según el conjunto porque dependen del ancho de las fisuras (ver la descripción de los datos), siendo 3, 5 y 7 pixeles para *CrackForest* y 10, 20 y 30 pixeles para *DeepCrack*. Los valores de los demás parámetros se acotaron en una exploración previa (Notebook, celdas [17] y [18]). La

selección es estable: en S2 y S3, la quinta mejor combinación queda a 0,023 de $F1_\tau$ o menos de la mejor. Sin embargo, varios óptimos quedaron en el borde de la rejilla, como el radio de 30 píxeles de S3 en DeepCrack, por lo que una rejilla más amplia podría mejorarlos ligeramente.

4. Evaluación comparativa de segmentadores

Cada segmentador se aplica, con los parámetros fijados en la calibración, a las 332 imágenes del subconjunto de evaluación: 95 de *CrackForest* y las 237 del *test* oficial de *DeepCrack*. Cada resultado se compara con su *ground truth* mediante el evaluador propio, descrito previamente, que calcula todas las métricas para cada imagen (Notebook, celdas [19] y [20]). Se registra, además, el tiempo de segmentación de cada imagen, que incluye el preprocesamiento. En la tabla 4 se resumen los resultados para el conjunto de imágenes de evaluación, presentando la media y la desviación estándar.

Tabla 4. Resultados de las métricas para los tres segmentadores.

Conjunto	Método	n	IoU	Dice	Precisión	Sensibilidad	F1_tol	clDice	T (s)
CrackForest	S1	95	0.142±0.126	0.230±0.171	0.163±0.170	0.747±0.140	0.339±0.224	0.241±0.194	0.00
	S2	95	0.376±0.122	0.534±0.140	0.488±0.139	0.634±0.203	0.744±0.173	0.616±0.172	0.03
	S3	95	0.353±0.140	0.506±0.161	0.550±0.163	0.500±0.206	0.699±0.192	0.593±0.193	0.04
DeepCrack	S1	237	0.438±0.286	0.552±0.291	0.565±0.356	0.779±0.223	0.632±0.308	0.573±0.332	0.01
	S2	237	0.618±0.192	0.745±0.169	0.764±0.200	0.807±0.204	0.842±0.166	0.794±0.161	0.06
	S3	237	0.626±0.174	0.754±0.149	0.878±0.184	0.694±0.152	0.844±0.150	0.807±0.145	0.10

Estos resultados se complementan con la aplicación de la prueba de rangos con signo de Wilcoxon (Wilcoxon, 1945), lo cual permite determinar si las diferencias entre los tres métodos son reales o pueden deberse al azar. Esta es una prueba no paramétrica para datos pareados, por lo que cada imagen se segmenta con los tres métodos, de modo que se comparan los métodos imagen a imagen, sin suponer que las métricas sigan una distribución normal (la figura 3 muestra distribuciones asimétricas y acotadas entre 0 y 1; Notebook, celda [21]).

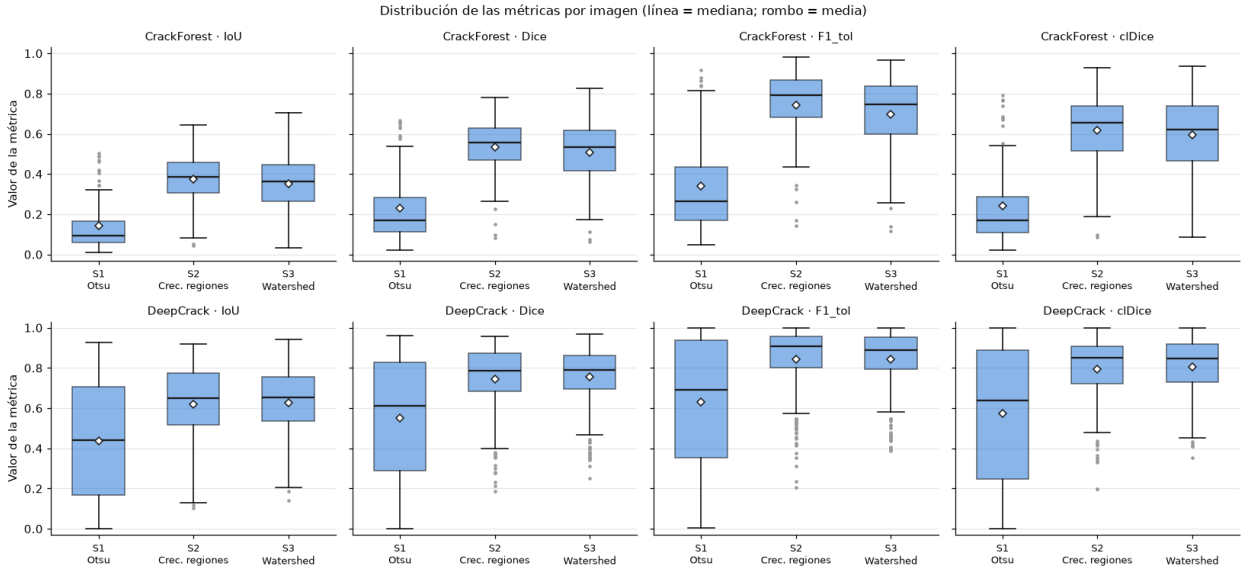


Figura 3. Diagramas de caja para los resultados de las métricas de evaluación

Se comparan los tres pares de métodos en cada conjunto y para tres métricas (*Dice*, *F1* con tolerancia y *clDice*), excluyendo *IoU* porque ordena las imágenes de la misma manera que *Dice* (apartado 2: Dice es una función creciente de IoU). Al hacer tres comparaciones sobre los mismos datos, aumenta la probabilidad de encontrar una diferencia "significativa" por azar. Por eso los p-valores se ajustan con el método de Holm (Holm, 1979). Una diferencia se considera significativa si el *p-valor* ajustado es menor que 0,05. Además del *p-valor*, se reportan dos medidas del tamaño de la diferencia: la mediana de la diferencia entre métodos y el porcentaje de imágenes en las que gana el primero. Con cientos de imágenes, una diferencia puede ser estadísticamente significativa y aun así pequeña en la práctica. La tabla 5 resume la comparación entre S2 y S3 (Notebook, celda [22]). Las comparaciones de S2 y S3 frente a S1 son significativas en ambos conjuntos y en las tres métricas (p ajustado < 10^{-14}).

Conjunto	**Métrica**	**Mediana de la diferencia (S2 − S3)**	**Imágenes en que gana S2**	**p ajustado (Holm)**	**Significativa**
CrackForest	Dice	+0,023	66 %	$1{,}1 \cdot 10^{-4}$	Sí
CrackForest	F1~τ~	+0,037	75 %	$1{,}0 \cdot 10^{-7}$	Sí
CrackForest	clDice	+0,013	56 %	$8{,}2 \cdot 10^{-3}$	Sí
DeepCrack	Dice	+0,004	54 %	0,59	No
DeepCrack	F1~τ~	+0,007	55 %	0,15	No
DeepCrack	clDice	−0,002	49 %	0,35	No

5. Análisis de los resultados

El umbral global de Otsu (S1) obtiene el peor resultado en ambos conjuntos, obteniendo valores para F1 con tolerancia de 0,34 en *CrackForest* y 0,63 en *DeepCrack*. Su sensibilidad es alta (0,75 y 0,78), pero su precisión es muy baja en *CrackForest* (0,16), lo que se puede interpretar como que detecta la fisura junto con gran parte de la textura del agregado. Como muestra el histograma del realce (Notebook, celda [14]), la fisura ocupa demasiado poco de la imagen para formar un modo propio en el histograma, y el umbral cae dentro de la distribución del fondo. En *DeepCrack* funciona mejor porque las fisuras son más anchas y contrastadas, pero su variabilidad es la mayor de los tres métodos (desviación de 0,31 en F1_tol), por lo que según la imagen que se analice, acierta o fracasa por completo.

En *CrackForest*, S2 supera a S3 de forma estadísticamente significativa en las tres métricas comparadas (p ajustado < 0,01; tabla 5). La diferencia es moderada: $F1_\tau$ de 0,744 frente a 0,699, y S2 gana en el 75 % de las imágenes. La causa está en la sensibilidad (0,63 frente a 0,50). En *Watershed*, la zona dudosa se reparte entre los marcadores de fisura y de fondo; con marcadores de fondo que cubren el 95 % de la imagen, los tramos tenues de fisura sin marcador propio quedan absorbidos por la cuenca del fondo. El crecimiento de regiones, en cambio, avanza por cualquier camino de píxeles admisibles conectado a una semilla y recupera más tramos tenues. S2 también generaliza mejor: su $F1_\tau$ apenas cambia entre calibración y evaluación (+0,005), mientras que el de S3 baja 0,035 (Notebook, celda [23]).

En *DeepCrack*, S2 y S3 no presentan diferencias significativas en ninguna métrica (p entre 0,15 y 0,59; tabla 5; cada uno gana en torno a la mitad de las imágenes). Sí difieren en su comportamiento: S3 es más preciso (0,88 frente a 0,76) y S2 más sensible (0,81 frente a 0,69). *Watershed* sitúa la frontera en el máximo del gradiente y es conservador. El crecimiento de regiones es más inclusivo. En auscultación, la elección dependería del objetivo: S2 si importa no omitir fisuras en el inventario, y S3 si importa delimitar con precisión el ancho, que determina la severidad. En este conjunto los tres métodos mejoran unos 0,05 de F1~τ~ entre calibración y evaluación (0,13 en S1), lo que indica que las imágenes de calibración eran más difíciles que las del *test*, no un sobreajuste.

Los mismos métodos obtienen un *Dice* muy inferior en *CrackForest* (0,52) que en *DeepCrack* (0,75). La diferencia se reduce con el F1 con tolerancia (0,72 frente a 0,84). Esto confirma el análisis del apartado 2: en estructuras de unos 3 píxeles, una parte de la penalización de IoU y Dice refleja la imprecisión de la anotación y no un error del método. Por eso los dos conjuntos no deben compararse en valor absoluto, y las conclusiones se apoyan en ambas familias de métricas.

La figura 4 ilustra los modos de fallo (Notebook, celda [24]). En el caso mediano (092), la rama tenue de la derecha carece de semillas y de marcadores, y S2 y S3 la pierden (falsos negativos), mientras que S1 la detecta junto con abundante textura. En el peor caso (052), la fisura cruza dos superficies distintas: en la zona heterogénea, las manchas oscuras generan falsos positivos y el tramo de bajo contraste no se detecta, de modo que los tres métodos obtienen $F1_\tau = 0{,}14$. En DeepCrack, el black-hat solo realza zonas oscuras más estrechas que su disco; en desconchados de unos 50 píxeles de ancho solo se detectan los bordes (imagen 11231-6). Juntas, las manchas y las sombras también producen falsos positivos.

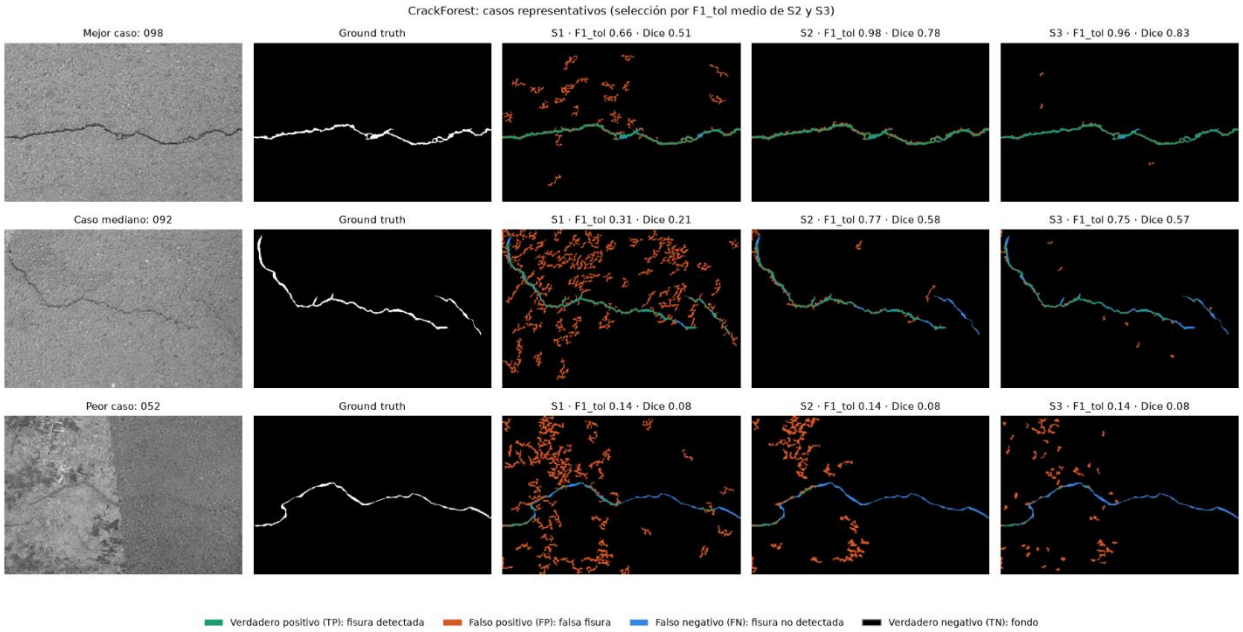


Figura 4. Casos representativos de CrackForest: mejor (098), mediano (092) y peor (052) resultado. Verde: verdadero positivo; naranja: falso positivo; azul: falso negativo

Los tres métodos segmentan una imagen en menos de 0,1 segundos o menos en un ordenador personal, incluido el crecimiento de regiones de implementación propia en Python. Esto los hace viables para procesar los miles de imágenes de una campaña de auscultación.

6. Conclusiones

Se compararon tres segmentadores clásicos de fisuras sobre 332 imágenes de evaluación de dos conjuntos públicos, con un evaluador de implementación propia validado con casos de resultado conocido. Las conclusiones principales son cuatro:

1. Las dos técnicas de crecimiento de regiones del tema 10 superan con claridad a la umbralización global de Otsu, que confunde la fisura con la textura del agregado ($F1_\tau$ de 0,34 en *CrackForest*).
2. En fisuras finas y de bajo contraste (*CrackForest*), el crecimiento de regiones a partir de semillas es significativamente mejor que *Watershed* con marcadores, porque recupera los tramos tenues

conectados a la fisura. En fisuras anchas (*DeepCrack*) no hay diferencias significativas, y la elección depende del objetivo: *Watershed* es más preciso y el crecimiento de regiones, más sensible.

3. La evaluación de estructuras finas no debe basarse únicamente en *IoU* o *Dice*. Un desplazamiento de 2 píxeles reduce el *IoU* de una anotación perfecta a 0,31 en *CrackForest*, por lo que $F1_\tau$ y *clDice* son necesarios para evaluar la localización y la continuidad. Por la misma razón, los valores de ambos conjuntos no son comparables en términos absolutos.
4. La calidad del *Ground Truth* condiciona la evaluación: tres anotaciones de *CrackForest* no correspondían a su imagen y fueron detectadas mediante un control objetivo previo.

Bibliografía

ASTM International. (2024). Standard practice for roads and parking lots pavement condition index surveys (ASTM D6433-24). ASTM International.

Beucher, S. y Lantuéjoul, C. (1979). Use of watersheds in contour detection. En *International Workshop on Image Processing: Real-time Edge and Motion Detection/Estimation*, Rennes, Francia.

Dice, L. R. (1945). Measures of the amount of ecologic association between species. Ecology, 26(3), 297–302.Gonzalez, R. C. y Woods, R. E. (2018). Digital image processing (4.ª ed.). Pearson.

Gonzalez, R. C. y Woods, R. E. (2018). Digital image processing (4.ª ed.). Pearson.

Holm, S. (1979). A simple sequentially rejective multiple test procedure. Scandinavian Journal of Statistics, 6(2), 65–70.

Jaccard, P. (1912). The distribution of the flora in the alpine zone. New Phytologist, 11(2), 37–50.Koch, C., Georgieva, K., Kasireddy, V., Akinci, B. y Fieguth, P. (2015). A review on computer vision based defect detection and condition assessment of concrete and asphalt civil infrastructure. Advanced Engineering Informatics, 29(2), 196–210.

Koch, C., Georgieva, K., Kasireddy, V., Akinci, B. y Fieguth, P. (2015). A review on computer vision based defect detection and condition assessment of concrete and asphalt civil infrastructure. Advanced Engineering Informatics, 29(2), 196–210.

Liu, Y., Yao, J., Lu, X., Xie, R. y Li, L. (2019). DeepCrack: A deep hierarchical feature learning architecture for crack segmentation. Neurocomputing, 338, 139–153.Maier-Hein, L., Reinke, A., Godau, P., et al. (2024). Metrics reloaded: Recommendations for image analysis validation. *Nature Methods, 21*, 195–212.

Martin, D. R., Fowlkes, C. C. y Malik, J. (2004). Learning to detect natural image boundaries using local brightness, color, and texture cues. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 26*(5), 530–549.

Meyer, F. y Beucher, S. (1990). Morphological segmentation. *Journal of Visual Communication and Image Representation, 1*(1), 21–46.

Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics, 9*(1), 62–66.

Shahin, M. Y. (2005). Pavement management for airports, roads, and parking lots (2.ª ed.). Springer.

Shi, Y., Cui, L., Qi, Z., Meng, F. y Chen, Z. (2016). Automatic road crack detection using random structured forests. IEEE Transactions on Intelligent Transportation Systems, 17(12), 3434–3445.Shit, S., Paetzold, J. C., Sekuboyina, A., Ezhov, I., Unger, A., Zhylka, A., Pluim, J. P. W., Bauer, U. y Menze, B. H. (2021). clDice: A novel topology-preserving loss function for tubular structure segmentation. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 16560–16569).

Taha, A. A. y Hanbury, A. (2015). Metrics for evaluating 3D medical image segmentation: Analysis, selection, and tool. *BMC Medical Imaging, 15*, 29.

UNIR. (s. f.). Material de la asignatura Percepción Computacional, tema 10: Procesamiento de imagen. Crecimiento de regiones.

Vincent, L. y Soille, P. (1991). Watersheds in digital spaces: An efficient algorithm based on immersion simulations. *IEEE Transactions on Pattern Analysis and Machine Intelligence, 13*(6), 583–598.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. Biometrics Bulletin, 1(6), 80–83.

Zakeri, H., Nejad, F. M. y Fahimifar, A. (2017). Image based techniques for crack detection, classification and quantification in asphalt pavement: A review. Archives of Computational Methods in Engineering, 24(4), 935–977.